Regras de associação com o algoritmo Apriori — base Titanic

Paulo Gabriel de Oliveira Leite

1. Pré-processamento da base

(a) Ausentes e atributos removidos. Base Kaggle `train.csv` (891 passageiros). *Age* tinha 177 ausentes (19,9%), preenchidos com a **mediana da idade do grupo título do nome × classe** (*Master* = meninos, *Miss* = solteiras etc.). Com a mediana global (28 anos), todos cairiam na mesma faixa e criariam regras artificiais. *Embarked* (2 ausentes) recebeu a moda (Southampton). Foram removidos os identificadores *PassengerId*, *Name* e *Ticket*, que nunca atingiriam suporte mínimo, e *Cabin* (77% ausente). *SibSp* e *Parch* foram somados em *Família* = SibSp + Parch + 1.

(b) Discretização. As faixas buscam significado (comportamentos diferentes de sobrevivência) e suporte suficiente para aparecerem nos itemsets frequentes:

Atributo	Faixas (taxa de sobrevivência)	Justificativa
Idade	0-17 (54%) · 18-22 (37%) · 23-40 (36%) · 41+ (36%)	0-17 = menores (“mulheres e crianças primeiro”); 23-40 concentra a mediana (≈ 28); acima de 60 só há 22 pessoas, por isso 41+ é uma faixa única. Faixas mais finas teriam suporte < 5%.
Tarifa (£)	≤ 10 (20%) · 10-30 (43%) · > 30 (58%)	Cortes arredondados dos tercis (8,6 e 26,0) e quartis (7,9 / 14,5 / 31,0): três faixas de tamanho parecido.
Família	1 (30%) · 2-4 (58%) · 5+ (16%)	Separa quem viajava só, famílias pequenas e numerosas, com taxas bem diferentes.

Tabela 1 — Discretização dos atributos numéricos. Taxa geral de sobrevivência: 38,4%.

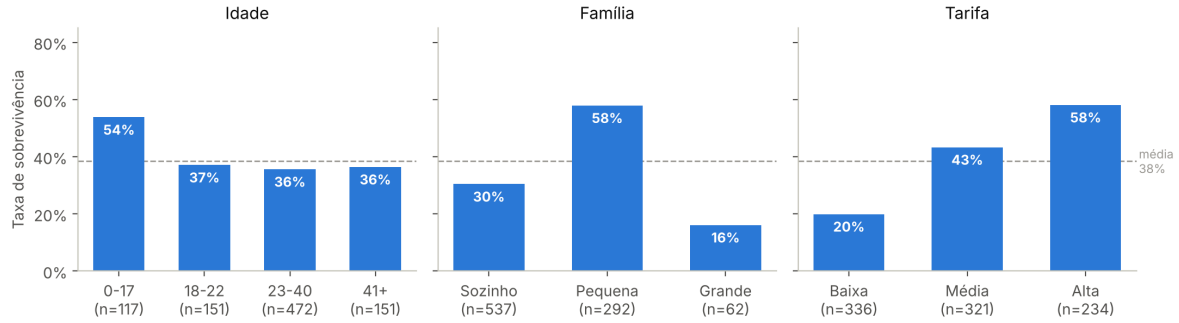


Figura 1 — Taxa de sobrevivência por faixa; a linha tracejada é a taxa geral (38%).

(c) Formato transacional. Com `pd.get_dummies`, cada par *atributo=valor* virou uma coluna booleana, e cada passageiro virou uma transação. São 20 itens de presença (Classe, Sexo, Idade, Família, Tarifa, Embarque e Sobreviveu). Exemplo: {Classe=3ª, Sexo=Masculino, Idade=18-22, Família=Pequena, Tarifa=Baixa, Embarque=Southampton, Sobreviveu=Não}.

2. Itens de ausência

Para cada item *A=v* criou-se a coluna *NÃO A=v*, a negação lógica da coluna original. Assim, *NÃO Classe=1ª* reúne 2ª e 3ª classes, e *NÃO Idade=0-17* significa “adulto”. A matriz final tem 36 colunas:

```
for coluna in itens_presenca.columns:
    if coluna.split('=')[0] in atributos_multivalor:          # atributos com 3+ valores
        itens_ausencia['NÃO ' + coluna] = ~itens_presenca[coluna]
transacoes = pd.concat([itens_presenca, itens_ausencia], axis=1)  # 891 x 36
```

- **Atributos binários ficaram de fora.** *NÃO Sexo=Feminino* é igual a *Sexo=Masculino* e só duplicaria regras. Os 16 itens de ausência são de Classe, Idade, Família, Tarifa e Embarque.
- **Tautologias removidas.** Itemsets com o mesmo atributo repetido foram descartados após o Apriori. Por exemplo, {Classe=1ª} → {NÃO Classe=3ª} tem confiança de 100% por definição e não revela nada sobre os dados. Na configuração escolhida, os itemsets frequentes caíram de 13.140 para 6.024.

3. Geração das regras

(a) Execução. `apriori(transacoes, min_support, max_len=4)` (antecedente com até 3 itens) e `association_rules` do mlxtend. Como os itens de ausência têm suporte muito alto (até 93%), as

combinações explodem: sem tratamento, são 29.114 regras na configuração escolhida. Além das tautologias, foram aplicados três filtros: **(i)** consequente só com itens de presença, já que qualquer antecedente "implica" um item de suporte 90% com lift ≈ 1; **(ii)** lift ≥ 1,2; **(iii)** regras produtivas, ou seja, a confiança de A → C precisa superar em pelo menos 2 pontos percentuais a de toda regra com antecedente A′ ⊂ A.

(b) Ajuste de suporte e confiança. Foram testadas 30 combinações (Tabela 2).

Sup. mín.	Conf. ≥ 50%	Conf. ≥ 60%	Conf. ≥ 70%	Conf. ≥ 80%	Conf. ≥ 90%
3%	136.444 → **2.624** Sim 192 · Não 159	102.334 → **1.848** Sim 168 · Não 159	76.285 → **1.279** Sim 114 · Não 159	53.046 → **739** Sim 46 · Não 100	33.378 → **292** Sim 22 · Não 20
5%	117.617 → **1.924** Sim 134 · Não 124	88.548 → **1.317** Sim 112 · Não 124	65.520 → **880** Sim 73 · Não 124	44.495 → **481** Sim 36 · Não 70	27.133 → **159** Sim 16 · Não 8
8%	94.299 → **1.295** Sim 76 · Não 95	70.642 → **851** Sim 62 · Não 95	51.943 → **564** Sim 40 · Não 95	34.363 → **303** Sim 20 · Não 51	20.089 → **66** Sim 6 · Não 1
10%	80.808 → **1.049** Sim 61 · Não 89	60.789 → **680** Sim 47 · Não 89	44.622 → **450** Sim 29 · Não 89	29.114 → **238** Sim 18 · Não 48	16.356 → **41** Sim 5 · Não 0
15%	57.613 → **828** Sim 22 · Não 86	43.922 → **546** Sim 13 · Não 86	32.085 → **369** Sim 10 · Não 86	20.386 → **193** Sim 5 · Não 46	10.548 → **24** Sim 1 · Não 0
20%	43.962 → **681** Sim 10 · Não 78	33.727 → **462** Sim 5 · Não 78	24.223 → **312** Sim 5 · Não 78	14.627 → **153** Sim 1 · Não 40	7.339 → **15** Sim 0 · Não 0

*Tabela 2 — Regras brutas → **após filtros**; na 2ª linha, quantas concluem Sobreviveu=Sim / Não. Em destaque, a configuração escolhida.*

Escolha: **suporte ≥ 10% e confiança ≥ 80%**, resultando em **238 regras** (18 para Sobreviveu=Sim e 48 para Sobreviveu=Não). O suporte de 10% exige pelo menos 89 passageiros por regra. Com 3-5%, surgem 481-739 regras sobre subgrupos pequenos e sobrepostos. Com 15-20%, as regras de Sobreviveu=Sim quase somem, porque as mulheres da 1ª classe têm suporte de 0,102. A confiança de 80% implica lift ≥ 2,08 para Sobreviveu=Sim (base 38,4%) e ≥ 1,30 para Sobreviveu=Não (base 61,6%). Com 90% sobram só 5 regras de sobrevivência; com 70%, o total quase dobra (450) e, com 50%, passa de mil (1.049), sem trazer padrões novos.

(c) Métricas. Suporte = P(A ∪ C); confiança = sup(A ∪ C) / sup(A); lift = confiança / sup(C) (lift = 1 indica independência). As 238 regras, com as três métricas, estão listadas no notebook. 177 delas (74%) têm item de ausência no antecedente.

4. Análise dos resultados

(a) Regras mais relevantes (por lift)

#	Antecedente	Consequente	Sup.	Conf.	Lift
R1	{Classe=1ª, NÃO Família=Sozinho}	{Tarifa=Alta}	0,118	0,981	3,74
R2	{Classe=1ª, Família=Pequena}	{Tarifa=Alta}	0,111	0,980	3,73
R3	{Sobreviveu=Sim, Tarifa=Alta, NÃO Idade=0-17}	{Classe=1ª}	0,117	0,897	3,70
R4	{Tarifa=Alta, NÃO Família=Grande, NÃO Idade=0-17}	{Classe=1ª}	0,169	0,863	3,56
R5	{Sobreviveu=Sim, Tarifa=Alta}	{Classe=1ª}	0,129	0,846	3,49
R6	{Tarifa=Alta, NÃO Família=Grande}	{Classe=1ª}	0,183	0,840	3,47
R7	{Família=Pequena, Tarifa=Alta}	{Classe=1ª}	0,111	0,825	3,40
R8	{Tarifa=Alta, NÃO Idade=0-17}	{Classe=1ª}	0,176	0,809	3,34
R9	{Classe=1ª, Sobreviveu=Sim}	{Tarifa=Alta}	0,129	0,846	3,22
R10	{Classe=1ª, NÃO Idade=41+}	{Tarifa=Alta}	0,126	0,806	3,07

Tabela 3 — As 10 regras de maior lift (R# = posição na lista completa, ordenada por lift).

As regras de maior lift (3,1 a 3,7) ligam **classe e tarifa**, porque o preço da passagem é quase determinado pela classe. São fortes, mas previsíveis. As de sobrevivência começam logo depois, em R11: {Sexo=Feminino, Tarifa=Alta, NÃO Classe=3ª} → {Sobreviveu=Sim} (confiança 97,9%). A Figura 2 mostra todas as regras finais.

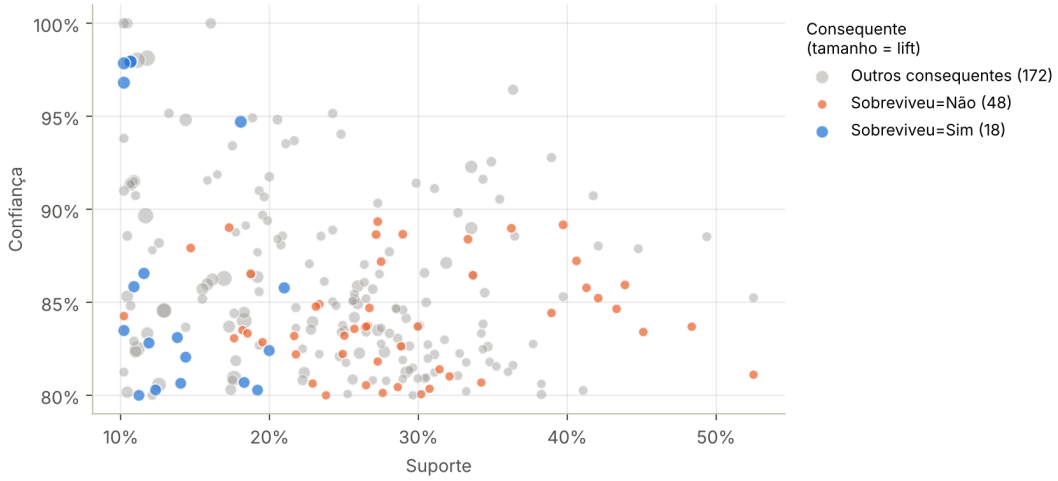


Figura 2 — As 238 regras finais (suporte × confiança). Azul: Sobreviveu=Sim (18); laranja: Sobreviveu=Não (48); cinza: outros consequentes. Tamanho = lift.

(b) Regras com consequente de sobrevivência

#	Antecedente	Sup.	Conf.	Lift
R11	{Sexo=Feminino, Tarifa=Alta, NÃO Classe=3ª}	0,107	0,979	2,55
R12	{Sexo=Feminino, NÃO Classe=3ª, NÃO Tarifa=Média}	0,107	0,979	2,55
R13	{Sexo=Feminino, Tarifa=Alta, NÃO Família=Grande}	0,102	0,978	2,55
R16	{Classe=1ª, Sexo=Feminino}	0,102	0,968	2,52
R18	{Sexo=Feminino, NÃO Classe=3ª}	0,181	0,947	2,47
R30	{Idade=23-40, Sexo=Feminino, NÃO Tarifa=Baixa}	0,116	0,866	2,25
R31	{Sexo=Feminino, Tarifa=Alta}	0,109	0,858	2,24
R32	{Sexo=Feminino, NÃO Família=Grande, NÃO Tarifa=Baixa}	0,210	0,858	2,23

*Tabela 4 — As 8 regras de maior lift (de 18) com consequente **Sobreviveu=Sim**.*

#	Antecedente	Sup.	Conf.	Lift
R98	{Sexo=Masculino, Tarifa=Baixa}	0,273	0,893	1,45
R100	{Sexo=Masculino, NÃO Classe=1ª, NÃO Idade=0-17}	0,397	0,892	1,45
R102	{Sexo=Masculino, NÃO Família=Pequena, NÃO Idade=23-40}	0,173	0,890	1,45
R104	{Sexo=Masculino, NÃO Classe=1ª, NÃO Família=Pequena}	0,363	0,890	1,44
R106	{Classe=3ª, Sexo=Masculino, NÃO Família=Pequena}	0,290	0,887	1,44
R107	{Idade=23-40, Sexo=Masculino, NÃO Classe=1ª}	0,272	0,886	1,44
R108	{Família=Sozinho, Sexo=Masculino, NÃO Classe=1ª}	0,333	0,884	1,44
R111	{Família=Sozinho, Sexo=Masculino, NÃO Idade=23-40}	0,147	0,879	1,43

*Tabela 5 — As 8 regras de maior lift (de 48) com consequente **Sobreviveu=Não**.*

- **Sobreviveu=Sim:** todas as 18 regras contêm *Sexo=Feminino*, e 14 usam itens de ausência. As mais fortes juntam o sexo a indicadores de classe e tarifa. Nenhuma regra com homens leva à sobrevivência: mesmo na 1ª classe, eles sobreviveram em só 36,9% dos casos. Mulheres da 3ª classe também ficam de fora (50,0% de sobrevivência).
- **Sobreviveu=Não:** a regra base é R179: {Sexo=Masculino} → {Sobreviveu=Não} (confiança 81,1%). As outras 47 refinam esse perfil com 3ª classe, tarifa baixa, idade adulta e viagem sem família; 36 delas usam ausência. Por exemplo, R124: {Classe=3ª, Sexo=Masculino} → {Sobreviveu=Não} chega a 86,5%.
- **Crianças não aparecem por falta de suporte, não de padrão.** Menores fora da 3ª classe sobreviveram em 91,4% dos casos, mas são só 35 passageiros (suporte 0,039 < 0,10).

(c) Interpretação de regras

1. Mulheres da 1ª classe
R16: {Classe=1ª, Sexo=Feminino} → {Sobreviveu=Sim} (sup. 0,102 · conf. 0,968 · lift 2,52)

Das 94 mulheres da 1ª classe, 91 sobreviveram. A chance é 2,52 vezes a taxa geral, e é o perfil de maior sobrevivência da base: combina os dois fatores mais fortes, sexo e classe.

2. Mulheres fora da 3ª classe (ausência)
R18: {Sexo=Feminino, NÃO Classe=3ª} → {Sobreviveu=Sim} (sup. 0,181 · conf. 0,947 · lift 2,47)

NÃO Classe=3ª junta as mulheres da 1ª (96,8%) e da 2ª classe (92,1%) em um único item. A regra cobre quase o dobro da anterior (0,181 contra 0,102) e perde só 2,1 pontos percentuais de confiança. A fronteira que importa é **não estar na 3ª classe**, onde a sobrevivência feminina cai para 50,0%.

3. Homens adultos fora da 1ª classe (dupla ausência)
R100: {Sexo=Masculino, NÃO Classe=1ª, NÃO Idade=0-17} → {Sobreviveu=Não} (sup. 0,397 · conf. 0,892 · lift 1,45)

Esse grupo soma 397 passageiros (44,6% da base), e 89,2% deles morreram. Os dois itens de ausência excluem justamente os homens com alguma chance de sobreviver: os da 1ª classe (36,9%) e os meninos (40,3%). A regra retrata o protocolo “mulheres e crianças primeiro” somado ao privilégio da 1ª classe.

4. Mulheres sem família grande e sem tarifa baixa (dupla ausência)
R32: {Sexo=Feminino, NÃO Família=Grande, NÃO Tarifa=Baixa} → {Sobreviveu=Sim} (sup. 0,210 · conf. 0,858 · lift 2,23)

Entre as 218 mulheres nesse grupo, 85,8% sobreviveram. As ausências excluem as famílias numerosas e as passagens baratas, concentradas na 3ª classe (87% e 96% delas, respectivamente). Mesmo entre as mulheres, a condição socioeconômica pesava.

5. Perfil: 1ª classe acompanhada → tarifa alta (ausência)
R1: {Classe=1ª, NÃO Família=Sozinho} → {Tarifa=Alta} (sup. 0,118 · conf. 0,981 · lift 3,74)

É a regra de maior lift. O campo *Fare* é o preço do **bilhete**, em geral compartilhado pela família. Por isso, famílias da 1ª classe aparecem com valor alto. Regras como R5: {Sobreviveu=Sim, Tarifa=Alta} → {Classe=1ª} mostram que associação não é causalidade: a tarifa alta indica a classe, e é a classe que se relaciona com o acesso aos botes.

Conclusão

O **sexo** foi o fator dominante na sobrevivência, e a **classe** (refletida na tarifa), o principal modulador. Os itens de ausência expressam grupos que não cabem em um único valor (*NÃO Classe=3ª* = 1ª ou 2ª; *NÃO Idade=0-17* = adultos), gerando regras mais gerais. Em compensação, multiplicam o número de regras e exigem a remoção de tautologias e filtros de qualidade. O principal limite da configuração é o suporte de 10%, que deixa de fora padrões fortes de grupos pequenos, como o das crianças da 1ª e 2ª classes.

Nota: foi utilizada Inteligência Artificial para a correção do português e para a geração dos gráficos apresentados neste PDF.